

Размер изображения: $H = W = S$

$$1 \text{ MAC} = 2 \text{ FLOPs}$$

Свёртки размером $K \times K$, padding P , stride S_{tr} , Bias = false

Формула выходного элемента свёртки:

$$Y_{C_{out}, h, w} = \sum_{n=0}^{C_{in}-1} \sum_{i=0}^{K-1} \sum_{j=0}^{K-1} W_{n, C_{out}, n, i, j} \cdot X_{n, h \cdot S_{tr} + i, w \cdot S_{tr} + j}$$

получается $K \cdot K \cdot C_{in}$ MAC = $2 \cdot K \cdot K \cdot C_{in}$ FLOPs

Эта формула выражается C_{out} раз $\Rightarrow$

кол-во операций нужно домножить на C_{out}

$$\text{Итого, кол-во FLOPs для одного (выходного) пикселя} = 2 \cdot K^2 \cdot C_{in} \cdot C_{out}$$

H_{out} - кол-во выходных пикселей по горизонтали, W_{out} - по вертикали. $\therefore$ нас $H_{out} = W_{out}$.

$$\text{Количество операций для одного выходного примера} = 2 K^2 \cdot C_{in} \cdot C_{out} \cdot H_{out} \cdot W_{out}$$

$$H_{out} = W_{out} = \left\lfloor \frac{H_{in} + 2 \cdot P - K}{S_{tr}} + 1 \right\rfloor$$

Также нам нужно учесть все примеры в батче
кол-во операций в одном свёрточном слое

$$\boxed{FLOPs(S, B) = 2 K^2 \cdot C_{in} \cdot C_{out} \cdot B \cdot \left(\left\lfloor \frac{H_{in} + 2P - K}{S_{tr}} + 1 \right\rfloor \right)^2}$$

Для матричного произведения ~~без~~ bias $f(x) = xWT$
 $X \in \mathbb{R}^{B \times \text{in-feats}}$, $W \in \mathbb{R}^{\text{out-feats} \times \text{in-feats}}$

$$\text{MAC} = B \cdot \text{in-feats} \cdot \text{out-feats} \quad (S=1, \text{ m.k.})$$

по этому случаю Global average pooling)

$$\boxed{\text{FLOPs} = 2B \cdot \text{in-feats} \cdot \text{out-feats}}$$

В ~~этом~~ нашем задании мы используем MAC -
 конвенцию (также она используется в PyTorch profiler).

ReLU и Maxpooling не используются операциями
 с Floating point числами $\Rightarrow$ мы не учитываем
 их в FLOPs. Глоба

Global average pooling ~~учитываем~~ выполняет
 усреднение по всем пикселям для каждого

C-out. ~~и~~ Когда он применяется

размер feature map $\frac{S}{16} \times \frac{S}{16}$, C-out=512

$$\boxed{\text{FLOPs}(S, B) = B \cdot 512 \cdot \frac{S^2}{16^2} = 2BS^2}$$

$$\text{Approx: } \text{FLOPs}(S, B) = \sum_{i \in \{\text{conv}_1, \dots, \text{conv}_6\}} \text{FLOPs}_{\text{conv}_i} + \sum_{j \in \{\text{Linear}_1, \text{Linear}_2\}} \text{FLOPs}_{\text{Linear}_j} + \text{FLOPs}_{\text{AVG-pool}}$$

(.) K	C _{in}	C _{out}	M _{out} × W _{out}	Flops
4	3	32	$\frac{S^2}{16}$	2352 2352 BS ²
5	32	64	$\frac{S^2}{16}$	6400 BS ²
3	64	128	$\frac{S^2}{64}$	2304 BS ²
1	128	256	$\frac{S^2}{64}$	1024 BS ²
3	256	512 256	$\frac{S^2}{256}$	4608 BS ²
1	256	512	$\frac{S^2}{256}$	1024 BS ²

$$(\dots) B(1024 \cdot 256 + 200 \cdot 256) = 313344 B$$

$$(\dots) 2 B \cdot S^2$$

$$\begin{aligned} \text{FLOPs}(S, B) &= (2352 + 6400 + 2304 + 1024 + 4608 + 1024) B S^2 \\ &+ 313344 B + 2 B \cdot S^2 = 17712 B S^2 + 313344 B + \\ &+ 2 B S^2 = \boxed{17714 B S^2 + 313344 B} \end{aligned}$$

Память считаем как сумму байтов на параметры и на активации. Данные и веса в fp32 $\Rightarrow$ 4 байта

$$\text{Memory}(B, S) = M_{\text{params}}^{(\bullet\bullet)} + M_{\text{act}}^{(\bullet\bullet)} + M_{\text{inp}}^{(\bullet\bullet\bullet)}$$

$$\begin{aligned} (\bullet) M_{\text{params}} &= 4 \cdot (N_{\text{conv1}} + N_{\text{conv2}} + N_{\text{conv3}} + N_{\text{conv4}} + N_{\text{conv5}} + \\ &\quad + N_{\text{Linear1}} + N_{\text{Linear2}} + N_{\text{conv6}}) = 4(3 \cdot 32 \cdot 4^2 + 32 \cdot 64 \cdot 5^2 + 64 \cdot 128 \cdot 3^2 + \\ &\quad + 128 \cdot 256 + 3 \cdot 256 \cdot 256 + 256 \cdot 512 + 512 \cdot 256 + \\ &\quad + 256 \cdot 100) = 4 \cdot 1040324 = 4161296 \end{aligned}$$

$$(\bullet\bullet) M_{\text{act}} = (\bullet\bullet\bullet) M_{\text{inp}} = 3 \cdot B \cdot S^2 \cdot 4$$

Tensor	Число эл.
Input	

($\bullet\bullet$) ~~M_{act}~~

Активация	Число элементов
Conv 7x7 3 $\rightarrow$ 32	8 B S ²
MaxPool	2 B S ²
Conv 5x5 32 $\rightarrow$ 64	4 B S ²
Conv 3x3 64 $\rightarrow$ 128	2 B S ²
Conv 1x1 128 $\rightarrow$ 256	4 B S ²

Активация	Число эл-ов
Conv 3x3 256 $\rightarrow$ 256	B S ²
Conv 1x1 256 $\rightarrow$ 512	2 B S ²
Global Avg Pool	512 B
Linear 512 $\rightarrow$ 256	256 B
Linear 256 $\rightarrow$ 100	100 B

$$M_{inp} = (8 + 2 + 4 + 2 + 4 + 1 + 2 + \cancel{512} + \cancel{256} + \cancel{100}) B S^2 +$$

$$+ (512 + 256 + 100) B = (23 B S^2 + 868 B) \cdot 4$$

$$\boxed{\text{Memory}(B, S)} = 4161296 + (3 B S^2 + 23 B S^2 + 868 B) =$$

$$= \boxed{\cancel{4161296} + B(104 S^2 + 3472)}$$

$$\cdot 4159872$$

number of Bytes moved = $Q(S, B) = \text{Bytes} \cdot (\text{num}$

$= 4 \cdot \sum_{i \in \text{layers}} (\text{input}_i + \text{output}_i + \text{num_params}_i)$

layer	Input	Output	num-params
conv 2x4	$3BS^2$	$8BS^2$	32 4704
conv	$8BS^2$	$8BS^2$	—
ReLU	$8BS^2$	$2BS^2$	—
MaxPool	$2BS^2$	$4BS^2$	$32 \cdot 64 \cdot 5^2 = 51200$
conv 3x5	$4BS^2$	$2BS^2$	43728
ReLU	$2BS^2$	$2BS^2$	—
conv 1x1	$2BS^2$	$4BS^2$	32768
conv 3x3	$4BS^2$	BS^2	589824
conv 1x1	BS^2	$2BS^2$	131072
ReLU	$4BS^2$	$4BS^2$	—
ReLU	BS^2	BS^2	—
ReLU	$2BS^2$	$2BS^2$	—

Global avg Pool	$2B \cdot 5^2$	$512B$	—
Linear $512 \rightarrow 256$	$512B$	$256B$	$512 \cdot 256$
ReLU	$256B$	$256B$	—
Linear $256 \rightarrow 100$	$256B$	$100B$	$256 \cdot 100$

$$Q(S, B) = 4(91B S^2 + 2148B + 1039968) =$$

$$= 364BS^2 + 8592B + 4159872$$

Число записов CUDA (компиляция = одна операция = одна Cuda launch) $L = n_{conv} + n_{pool} + n_{relu} + n_{linear}$

$$= 4 + 6 + 2 + 2 = 14$$

$\frac{1}{2}$

Для оценки latency используем гофлайн-модель, которая позволяет записывать переход из launch-bound в compute-bound в memory-bound в compute-bound.

$$Latency(S, B, \Theta) = L \cdot T + \max \left(\underbrace{\frac{Q(S, B)}{B}}_{T_{launch}}, \underbrace{\frac{FLOPs(S, B)}{\pi}}_{T_{memory}} \right) \cdot T_{compute}$$

$\Theta = (T, \beta, \pi)$; T - среднее время запуска CUDA-ядра, секунды; β - пропускная способность памяти, байт/секунду; π - эффективная вычислительная производительность, FLOPs.

При малых S, B доминирует T_{launch} , при больших $T_{memory} >$

$T_{compute} \Rightarrow$ compute-bound, иначе memory-bound

У нас в модели:

$$Latency(S, B, \Theta) = 14T + \max \left(\frac{4194BS^2 + 2142B + 1040824}{B}, \frac{14714BS^2 + 313344B}{\pi} \right)$$

Энергия Энергия в физическом смысле $E = \int_{t_0}^{t_f} P_{GPU}(t) dt$ измеряется в ~~Вт~~ Дж. Будем моделировать термы как сумму форм расходов одного forward базового потребления потребления GPU, энергии вычисления, энергии перемещения данных

$$E = E(S, B, \theta) = P_0 \cdot \overset{\text{Latency}(S, B)}{T(S, B)} + E_F \cdot \overset{\text{FLOPs}(S, B)}{F(S, B)} + E_Q \cdot Q(S, B)$$

P_0 - базовая мощность GPU, ватт

E_F - энергия одной FLOP, $\frac{\text{Дж}}{\text{FLOP}}$

E_Q - энергия перемещения одного байта, $\frac{\text{Дж}}{\text{byte}}$

$$E(S, B, \theta) = \cancel{P_0 \cdot T(S, B)} \cdot P_0 \cdot \text{Latency}(S, B) + E_F \cdot \overset{\text{FLOPs}(S, B)}{F(S, B)} + E_Q$$

$$E(S, B, \theta) = P_0 \cdot \text{Latency}(S, B) + E_F (17914 BS^2 + 313344 B) + 4E_Q (5185^2 + 2148B + 1039968) E_Q (364 BS^2 + 8592B + 4159872)$$